

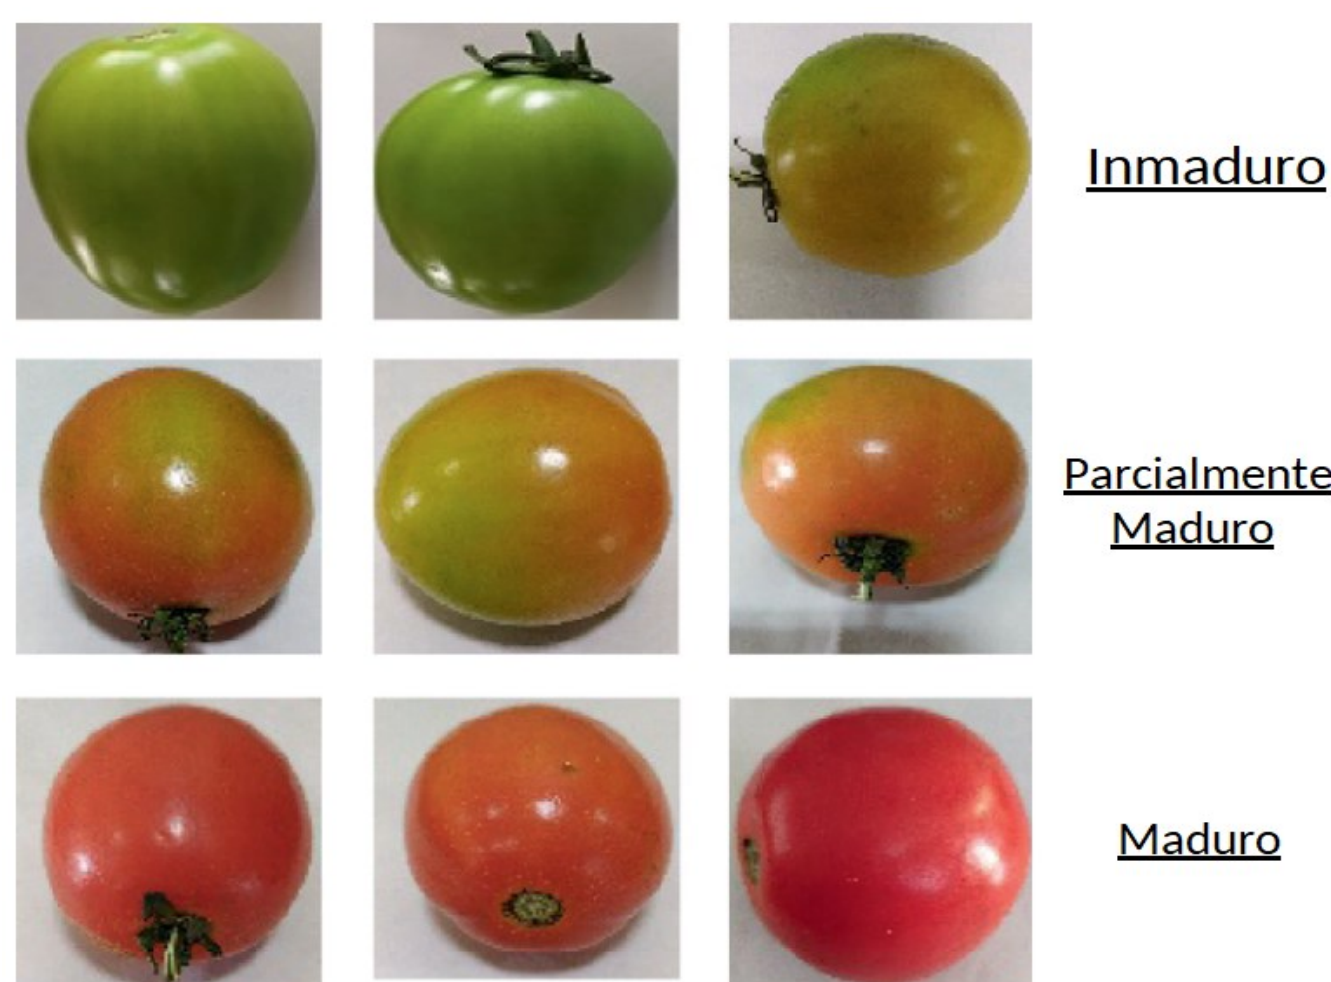
# Aplicación de Redes Neuronales Convolucionales para la Clasificación y Evaluación de la Madurez en Frutos

J.A. Rendón Vargas, J.A. Luna-Álvarez  
Tecnológico Nacional de México/Instituto Tecnológico de Chilpancingo  
Av. José Francisco Ruiz Massieu, No. 5, Fracc. Villa Moderna, C.P. 39090, Chilpancingo de los Bravo, Guerrero  
MG17520257@chilpancingo.tecnm.mx, jesus.la@chilpancingo.tecnm.mx

## 1. ANTECEDENTES

La evaluación manual de la calidad de la fruta, basada en valoraciones visuales y táctiles, es laboriosa y propensa a errores (Magabilin et al., 2022). Esto provoca pérdidas considerables en el sector agrícola.

Las tecnologías de aprendizaje profundo y visión por computadora ofrecen una solución eficaz. Begum y Hazarika (2022) demostraron la detección de la madurez de tomates mediante aprendizaje por transferencia, mientras que Azizi et al. (2024) y Olisah et al. (2024) emplearon redes profundas para clasificar fresas y moras negras, respectivamente.



**Figura 1.** Tres clases de maduración de los tomates, según Begum y Hazarika (2022)

MacEachern et al. (2023) aplicaron Redes Neuronales Convolucionales (CNN) para detectar etapas de madurez y estimar el rendimiento de arándanos silvestres. Estos estudios demuestran la precisión y eficiencia de estas tecnologías en la identificación de la madurez de las frutas, facilitando una agricultura más orientada a resultados y aplicable en tiempo real.

## 2. JUSTIFICACIÓN

La motivación de este artículo radica en la necesidad de mejorar los métodos tradicionales de evaluación de la madurez de frutas en la agricultura mediante el uso de Redes Neuronales Convolucionales. Estas tecnologías pueden transformar la industria al reducir el desperdicio de alimentos, mejorar la eficiencia en la distribución y aumentar la precisión en la evaluación de la madurez.

Este estudio se enfoca en dos estados de madurez debido a la variabilidad de los datos de diferentes fuentes y la necesidad de una base sólida antes de ampliar a más categorías. Esta simplificación inicial permite una evaluación más controlada y facilita la validación y adopción del modelo.

La implementación de CNN en la agricultura puede impulsar la innovación y sostenibilidad, promoviendo prácticas más eficientes. En futuras investigaciones, se podrán añadir más estados de madurez, ampliando la aplicabilidad del modelo.

## 3. OBJETIVO GENERAL

Diseñar y entrenar un modelo de clasificación de la madurez de diferentes frutas para reducir el índice de detección errónea utilizando redes neuronales convolucionales.


## 4. OBJETIVOS ESPECÍFICOS

1. Generar un conjunto de imágenes de las frutas seleccionadas en sus dos estados.
2. Diseñar la arquitectura del modelo de Red Neuronal Convolutional.
3. Entrenar el Modelo para la clasificación de las frutas.
4. Validar mediante métricas especializadas el desempeño del modelo.

## 5. PROPUESTA DE SOLUCIÓN

Se diseñó una CNN específica para clasificar imágenes de frutas, utilizando dos conjuntos de datos que suman 21,924 imágenes, divididas en 16,388 para entrenamiento y 5,536 para validación y pruebas.

Las imágenes fueron preprocesadas y aumentadas con técnicas como normalización y transformaciones para mejorar su generalización. Configurada para imágenes RGB, el entrenamiento se realizó durante 50 épocas con lotes de 16 imágenes, empleando el optimizador Adam y la pérdida de entropía cruzada categórica para clasificación multiclase. El diagrama del modelo está detallado en la Figura 2.



**Figura 2.** Arquitectura de la Red Neuronal Convolutional

## 6. ALCANCES

Propuesta de un modelo de clasificación supervisada empleando redes neuronales convolucionales, para clasificar cada fruta en dos estados: fresco y podrido. Los frutos analizados incluyen manzanas, plátanos, pepinos, naranjas y papas.


## 7. RESULTADOS

El dataset de validación consta de 5,536 imágenes en total. Se realizó la inferencia en cada una de las imágenes y se obtuvieron los siguientes resultados en las métricas de evaluación, como se ve en la Tabla 1.

Métrica	Puntuación
<i>Accuracy</i>	0.99169
<i>Precision</i>	0.99172
<i>Recall</i>	0.99169
<i>F1-Score</i>	0.99168

**Tabla 1.** Métricas obtenidas

También se obtuvo la matriz de confusión, como se puede ver en la Figura 3.



**Figura 3.** Matriz de confusión

## BIBLIOGRAFÍA

- Azizi, H., Asli-Ardeh, E.A., Jahanbakhshi, A., and Momeny, M. (2024). Vision-based strawberry classification using generalized and robust deep networks. *Journal of Agriculture and Food Research*, 15, 100931.
- Begum, N. and Hazarika, M.K. (2022). Maturity detection of tomatoes using transfer learning. *Measurement: food*, 7, 100038.
- MacEachern, C.B., Esau, T.J., Schumann, A.W., Hennessy, P.J., and Zaman, Q.U. (2023). Detection of fruit maturity stage and yield estimation in wild blueberry using deep learning convolutional neural networks. *Smart Agricultural Technology*, 3, 100099.
- Magabilin, M.C.V., Fajardo, A.C., and Medina, R.P. (2022). Optimal ripeness classification of the philippine guyabano fruit using deep learning. In *2022 Second International Conference on Power, Control and Computing Technologies (ICPC2T)*, 1–5. IEEE.
- Olisah, C.C., Trehwella, B., Li, B., Smith, M.L., Winstone, B., Whitfield, E.C., Fernandez, F.F., and Duncalfe, H. (2024). Convolutional neural network ensemble learning for hyperspectral imaging-based blackberry Fruit ripeness detection in uncontrolled farm environment. *Engineering Applications of Artificial Intelligence*, 132, 107945.